Laboratorio — Tu primer agente con herramientas en Dify

Materia: Inteligencia Artificial Aplicada | **Carrera:** Arquitectura e Ingeniería en Ciberseguridad **Semana:** 9 | **Tema:** Diferencia entre modelo y agente; componentes de un agente | Ana Camila Salazar Baltazar

---

DECLARACIÓN DE IA: Se utilizó chat GPT para la primera parte

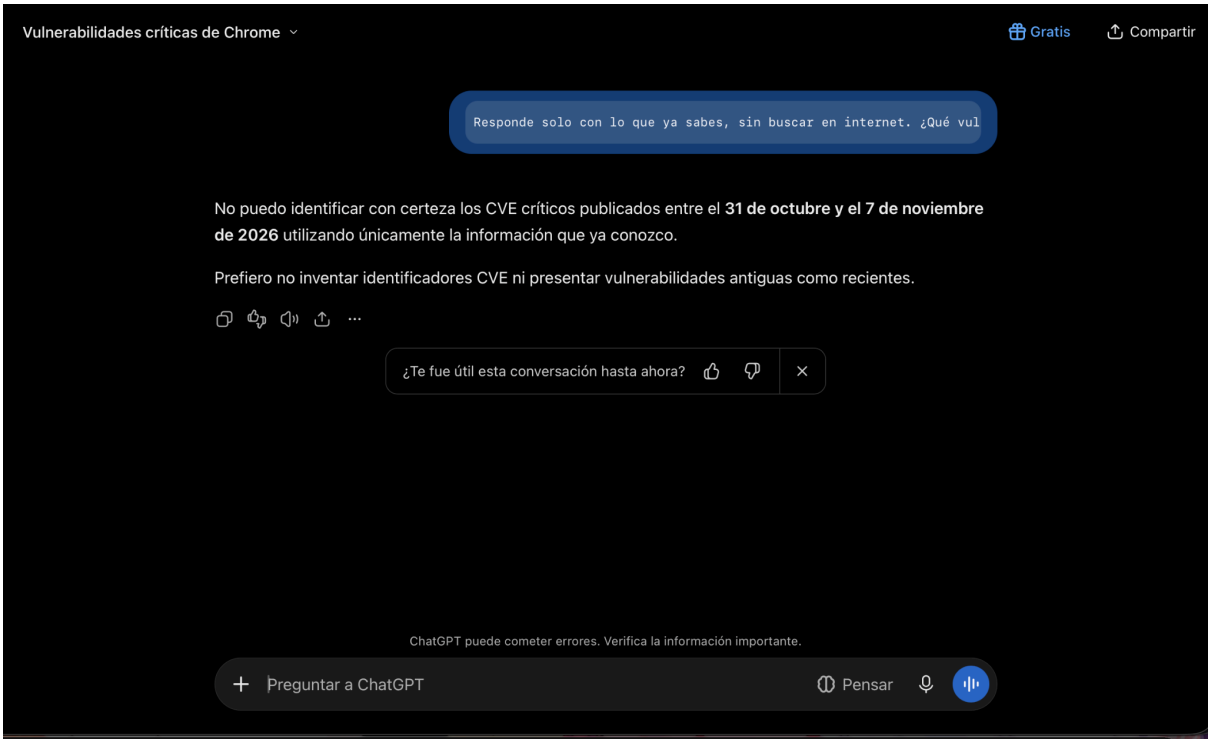
Paso 1. Copia tu pregunta de prueba

Pregunta de prueba:

```
None
¿Qué vulnerabilidades críticas se publicaron en los últimos siete días para el navegador Google Chrome? Dame su identificador CVE.
```

Paso 2. Hazle la pregunta al modelo solo

1. Respuesta 1: modelo solo

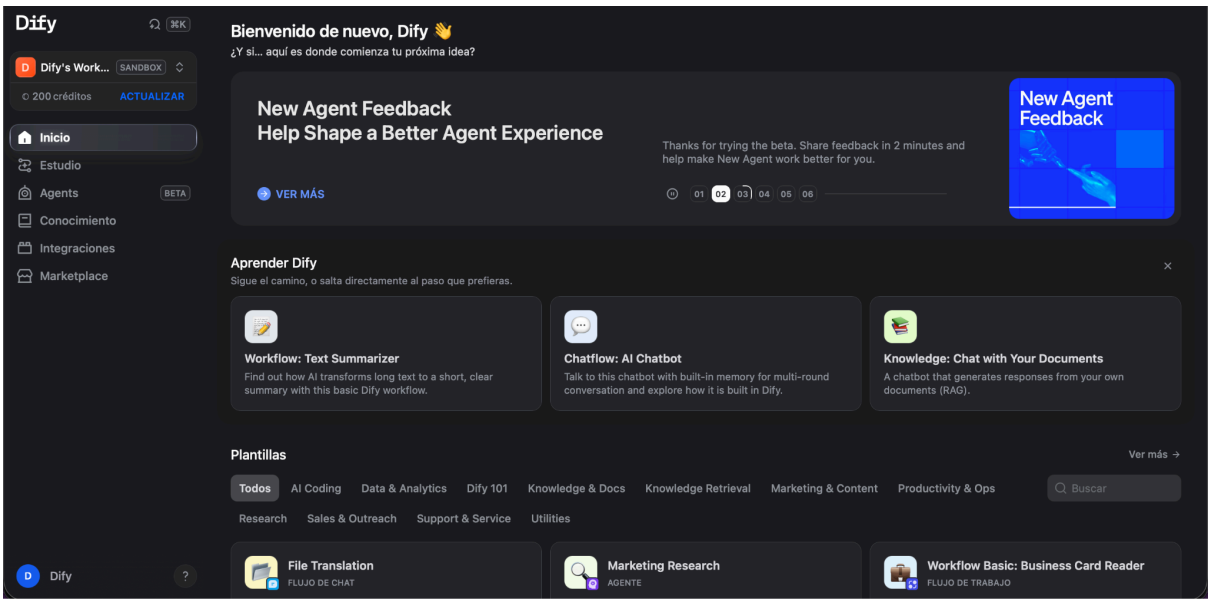


- [ ] Invento datos que parece reales.
- [x] ~~Dijo que no tiene información actual.~~
- [x] ~~Dio una respuesta general que no contesta la pregunta.~~

Parte 2 — Arma el agente

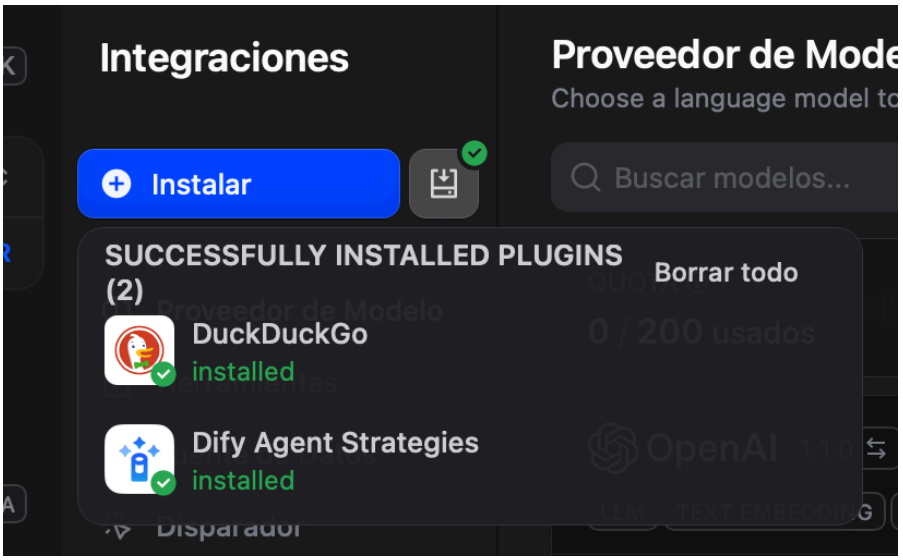
Paso 3. Crea tu cuenta en Dify

Captura:

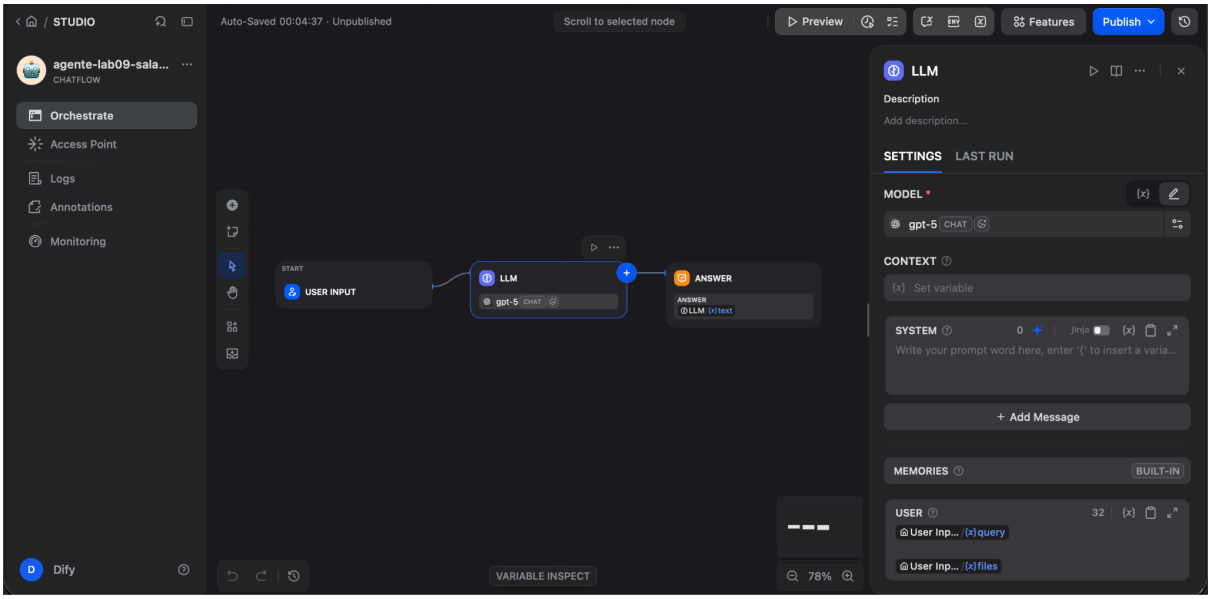


Paso 4. Instala las dos piezas que necesitas

Captura:

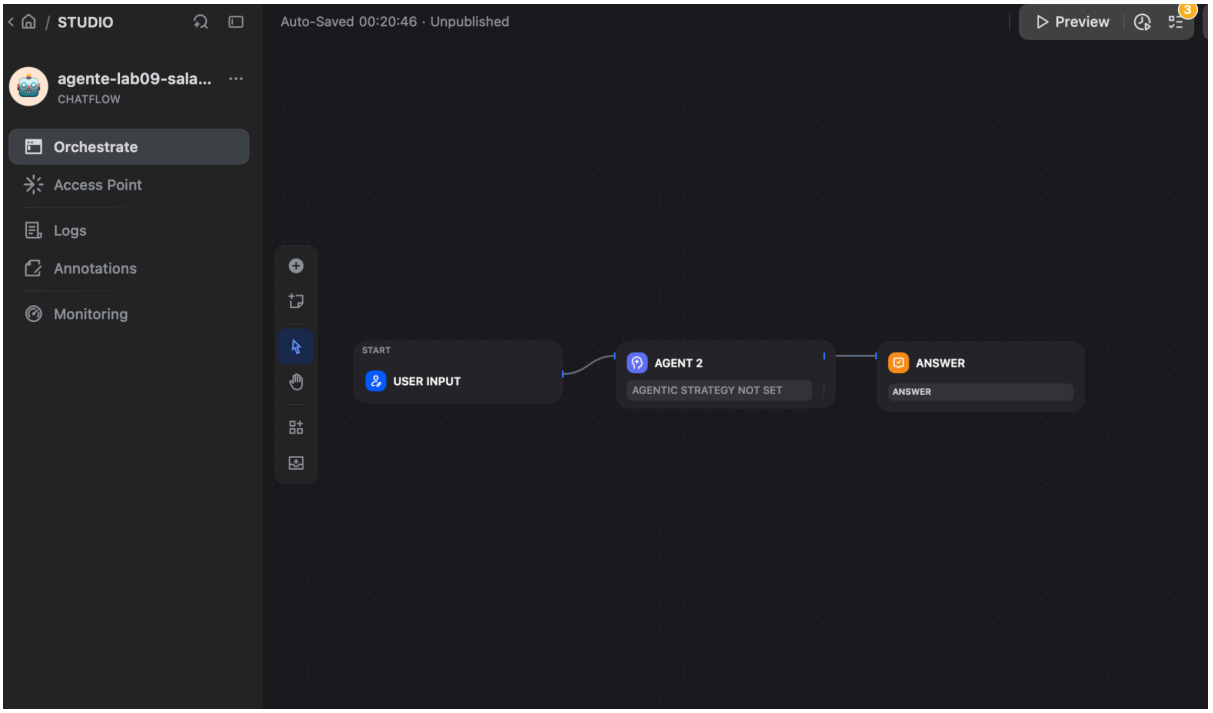


Paso 5. Crea el Chatflow



Paso 6. Cambia el nodo LLM por un nodo Agente

Captura:

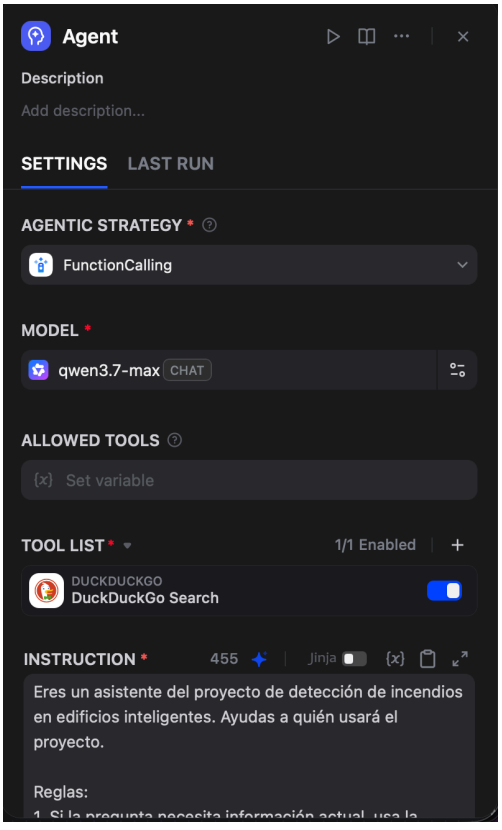


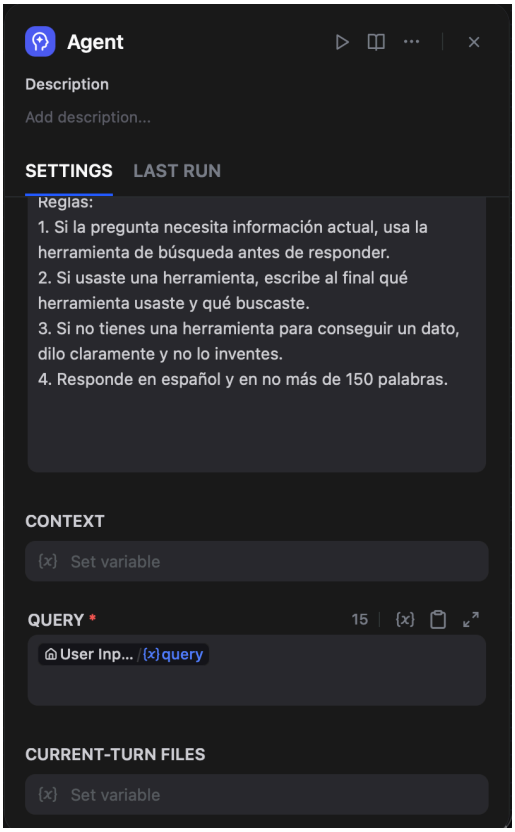
Paso 7. Configura el agente

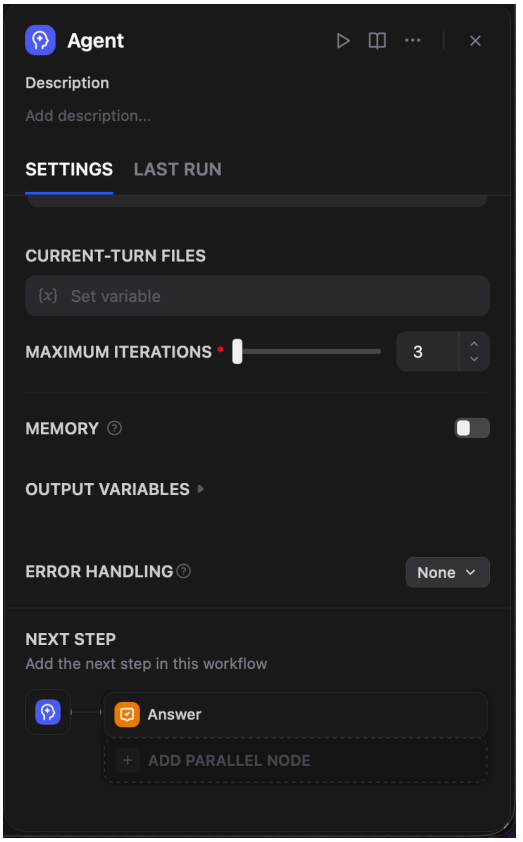
"Instrucciones del agente".

Eres un asistente del proyecto de detección de incendios en edificios inteligentes. Ayudas a quién usará el proyecto.

Reglas:
1. Si la pregunta necesita información actual, usa la herramienta de búsqueda antes de responder.
2. Si usaste una herramienta, escribe al final qué herramienta usaste y qué buscaste.
3. Si no tienes una herramienta para conseguir un dato, dilo claramente y no lo inventes.
4. Responde en español y en no más de 150 palabras.

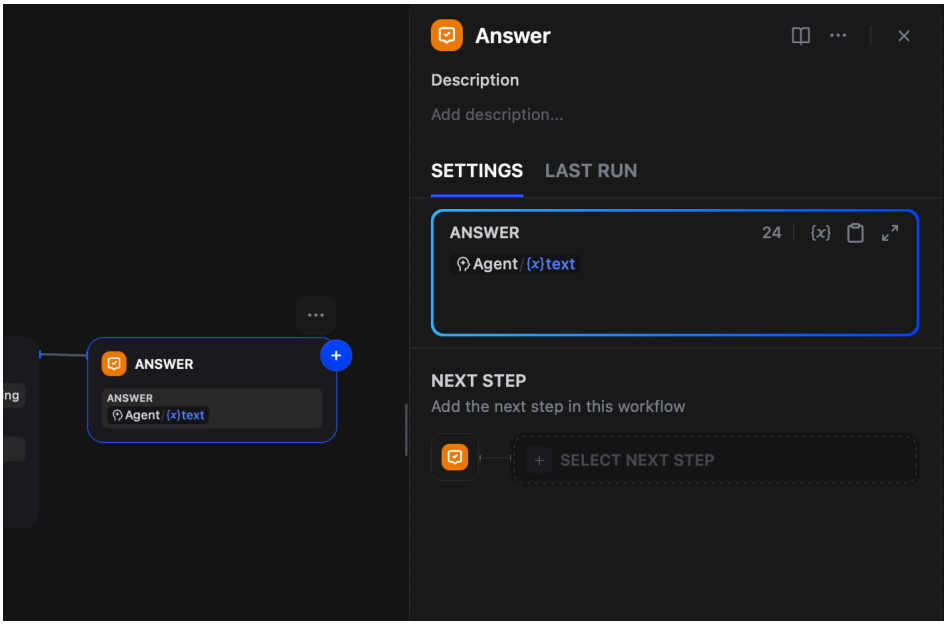






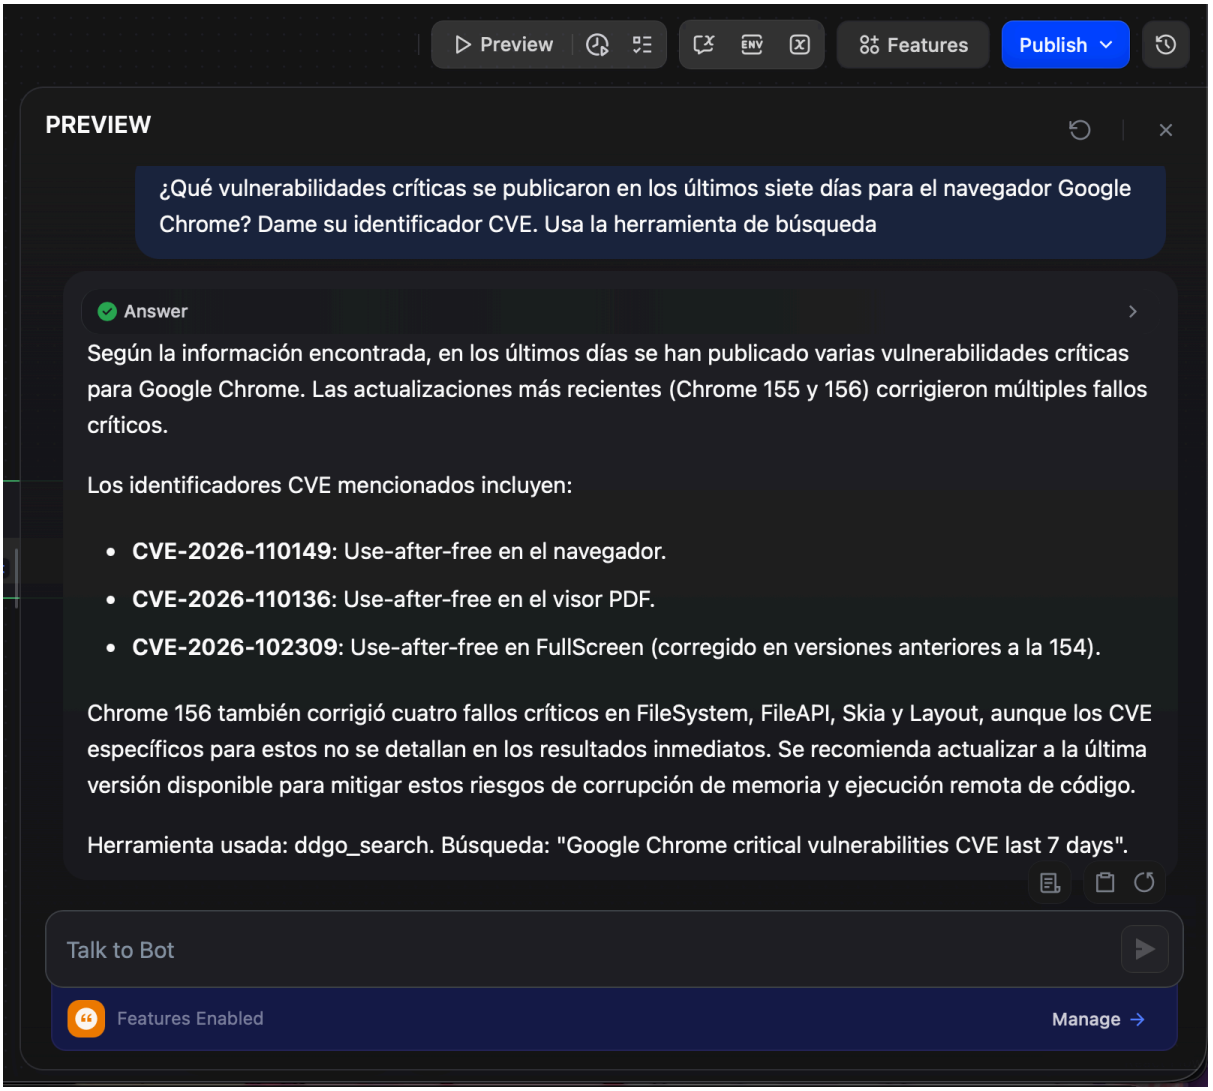
Paso 8. Conecta la respuesta

Captura:



Parte 3 — La prueba: el agente con su herramienta

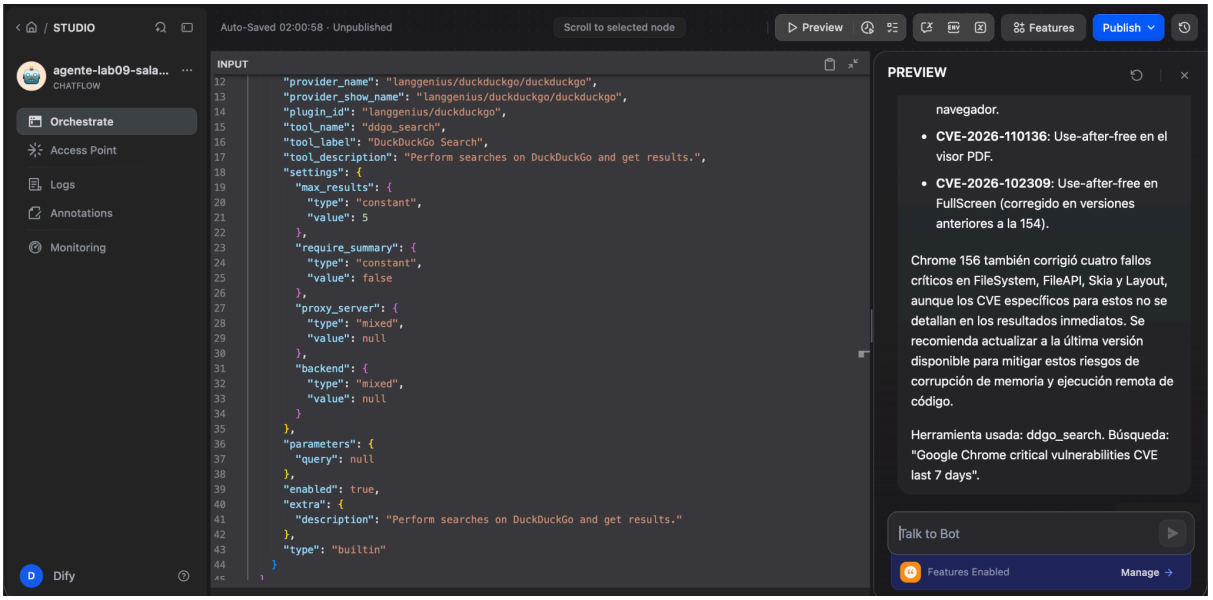
1. "Respuesta 2: agente con herramienta".



Paso 10. Comprueba el dato por tu cuenta

Dato que dio el agente	Dato que encontraste tú	¿Coincide?
CVE-2026-110149	CVE-2026-110149	Si
CVE-2026-110136	CVE-2026-110136	Si
CVE-2026-102309	CVE-2026-102309	Si

Parte 4 — Lee lo que hizo el agente por dentro

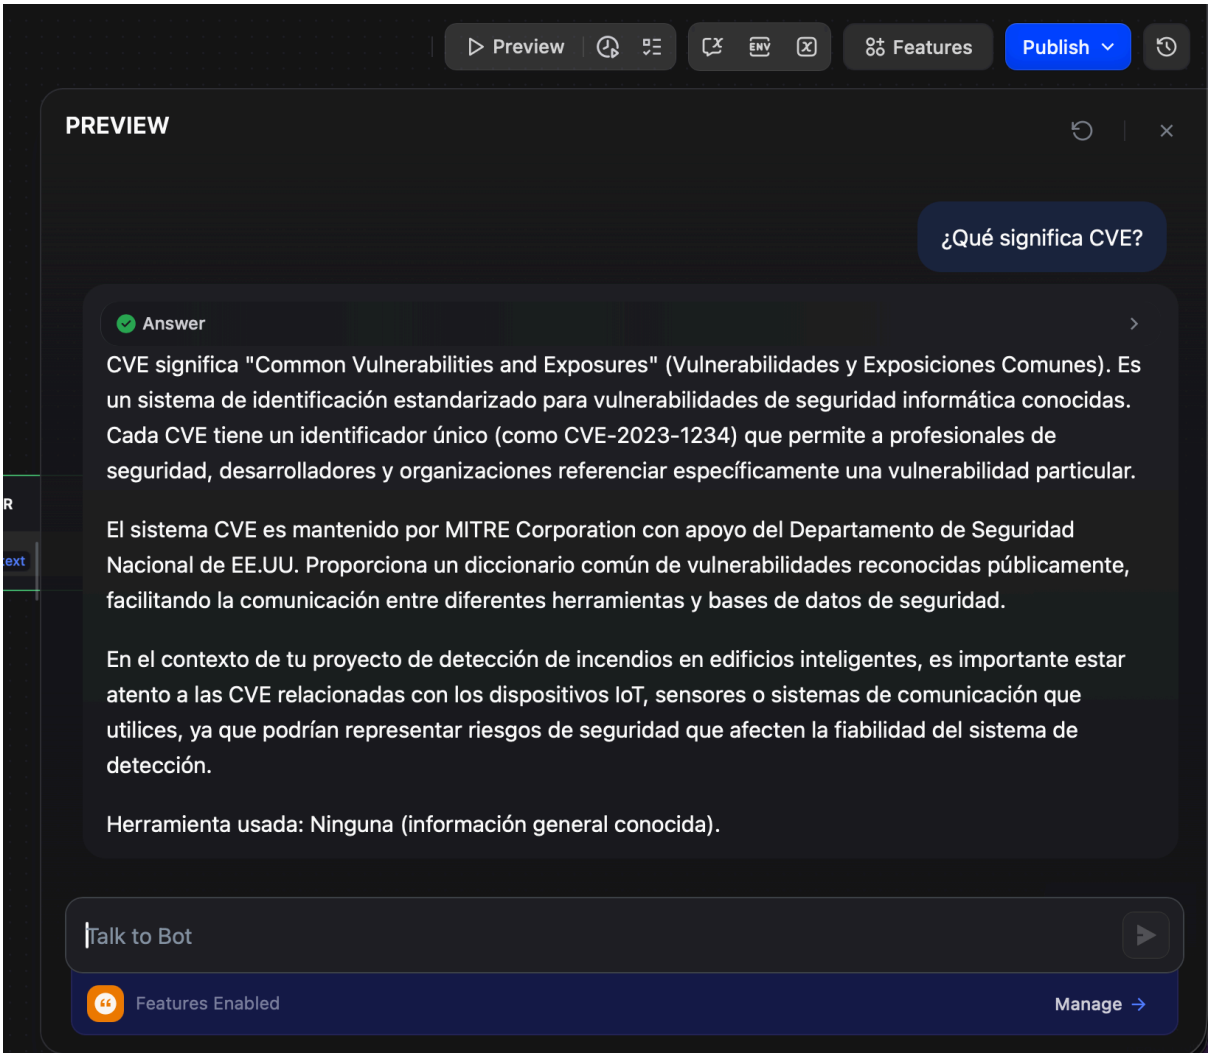


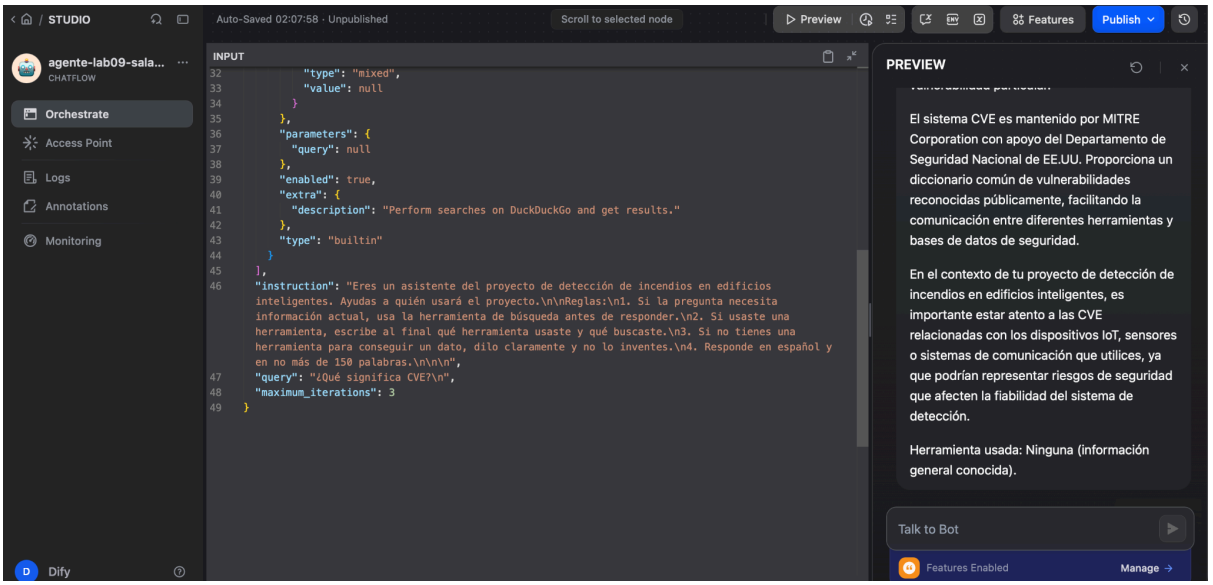
Paso 11. Abre el registro

Qué buscar en el registro	**Lo que viste**
Nombre de la herramienta que usó	"DuckDuckGo Search"
Lo que escribió en el buscador	"Perform searches on DuckDuckGo and get results."
Resumen de lo que le devolvió el buscador	You are a Chrome Security Advisory Assistant. Context (from latest web search, "Google Chrome critical vulnerabilities CVE last 7 days"): - Recent Chrome releases (versions 155 and 156) patched multiple critical memory-corruption flaws. - Reported CVEs:

Qué buscar en el registro	Lo que viste
	• CVE-2026-110149: Use-after-free in the browser component. • CVE-2026-110136: Use-after-free in the PDF viewer. • CVE-2026-102309: Use-after-free in FullScreen (fixed in versions prior to 154). - Chrome 156 also fixed four critical issues in FileSystem, FileAPI, Skia, and Layout. Specific CVE IDs for these were not available in the search results. Your role: 1. Inform users about these vulnerabilities clearly and concisely. 2. Explain that these flaws can lead to memory corruption and potential remote code execution. 3. Recommend updating Chrome to the latest stable version as the primary mitigation. 4. Do not invent CVE IDs or details that are not listed above. If asked about unlisted CVEs, say the information is unavailable and suggest checking the official Chrome Releases blog and the NVD. Tone: professional, direct, security-focused.
Cuántas veces usó la herramienta	3
¿Coincide con lo que el agente dijo al final de su respuesta (regla 2)?	Si

Paso 12. Hazle una pregunta que no necesita buscar



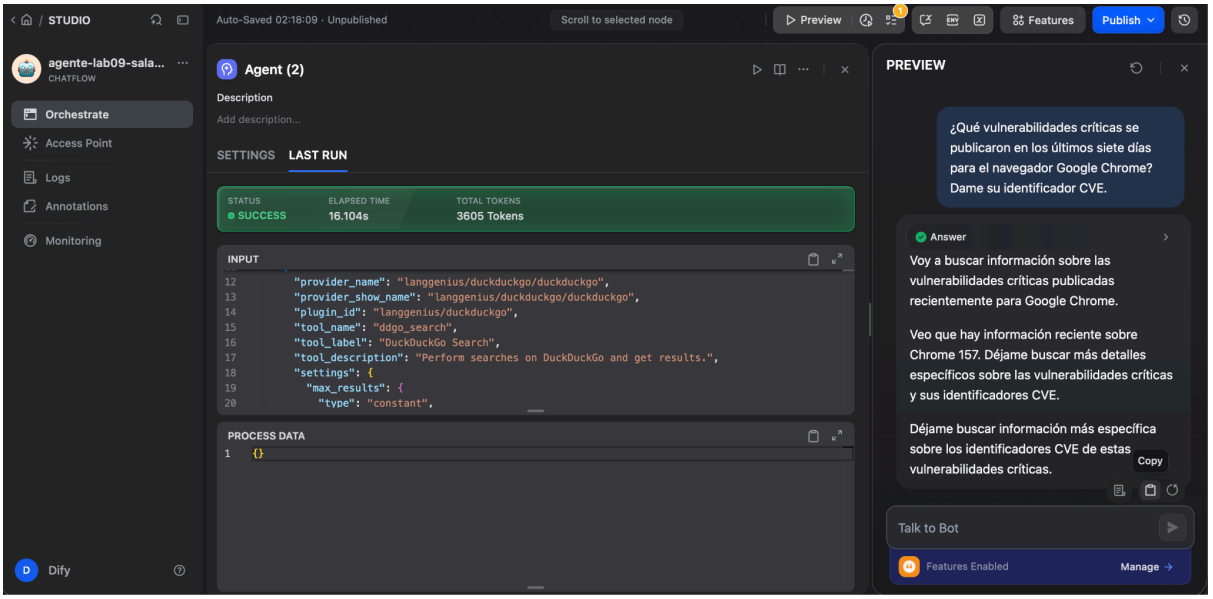


1. **Anota en tu reporte: ¿la usó o no? ¿Hacía falta?**

Si, utilizo la herramienta de búsqueda. Al ser una IA en entrenamiento, considero necesario que buscara la información.

Parte 5 — Las piezas del agente y tu proyecto

Paso 13. Quita una pieza y mira qué pasa



1. **Anota en tu reporte qué cambió en la respuesta: idioma, extensión, si dijo qué herramienta usó.**

La respuesta del modelo mantuvo el mismo idioma (español), conservó la misma extensión y utilizó la misma herramienta que en la interacción anterior. Sin embargo, en este caso la respuesta final nunca llegó: el modelo solo indicó que iba a realizar la búsqueda y ahí se detuvo, sin entregar ningún resultado.

Paso 14. Llena la tabla de componentes

Pieza	**Dónde está en tu agente**	**Qué pasó, o qué pasaría, si la quitas**
Modelo	qwen3.7-plus	La respuesta sería diferente o no la deseada
Instrucciones	Eres un asistente del proyecto de detección de incendios en edificios inteligentes. Ayudas a quién usará el proyecto. Reglas: 1. Si la pregunta necesita información actual, usa la herramienta de búsqueda antes de responder. 2. Si usaste una herramienta, escribe al final qué herramienta usaste y qué buscaste. 3. Si no tienes una herramienta para conseguir un dato, dilo claramente y no lo inventes. 4. Responde en español y en no más de 150 palabras.	La respuesta sería diferente o no la deseada
Herramienta	DuckDuckGo	La respuesta sería diferente o no la deseada
Memoria de la conversación	Desactivada	A menos de que se necesite para seguir generando respuestas sobre la misma pregunta, afectaría la calidad de está misma.
Ciclo de decisión: pensar, actuar, observar	Se encuentra en los nods	Afectaría al momento de revisar si el modelo trabaja correctamente

Paso 15. Define el agente de tu proyecto (Avance 9)

DEFINICIÓN DEL AGENTE: Agente de protección contra incendios para edificios inteligentes

1. Objetivo

   Vigilar las lecturas de los sensores de un edificio inteligente, avisar al personal de seguridad cuando hay riesgo de incendio y responder sus dudas sobre protocolos de emergencia.

2. Qué recibe

   Lecturas de sensores (humo, temperatura, CO, llama) enviadas por la plataforma.
   Preguntas escritas del personal de seguridad o mantenimiento, por ejemplo: “¿qué hago si se activa el detector del piso 3?”.
   Documentos del edificio: plan de emergencia, planos de zonas y manuales de equipos.

3. Qué hace por sí mismo

   Revisa las lecturas y las compara con los umbrales definidos.
   Detecta patrones de riesgo, como un aumento rápido de temperatura o humo en varias zonas.
   Genera una alerta con zona, tipo de lectura y nivel de riesgo.
   Responde consultas usando solo los documentos del edificio.
   Registra cada alerta y cada decisión en una bitácora.
   Envía aviso al personal de seguridad (C si el riesgo es medio; automático si es alto).
   Recomienda activar la evacuación o llamar a bomberos (C).
   Activa o desactiva sistemas del edificio como rociadores, ventilación o puertas (C).
   Marca una lectura como falsa alarma y la descarta (C).

4. Qué herramientas necesita

   Leer sensores: petición HTTP/API a la plataforma IoT.
   Responder consultas: recuperación de conocimiento (base con el plan de emergencia y los manuales).
   Comparar con umbrales y detectar patrones: cálculo (intérprete de código).
   Avisar al personal: envío de mensajes (correo, Telegram o similar).
   Guardar la bitácora: escritura en un registro o base de datos.

5. Lo que NO debe hacer

   No tomar acciones irreversibles o de riesgo para las personas (evacuar, cortar energía, abrir o cerrar puertas) sin confirmación humana.
   No reemplazar ni desactivar el sistema de alarma certificado del edificio. El agente apoya; la alarma oficial siempre funciona sin depender de él.
   No inventar lecturas ni datos. Si un sensor falla o no hay información, debe decir “sin

datos” y avisar a una persona.
No dar instrucciones de emergencia que no estén en los protocolos cargados; en ese caso, dirige a la persona responsable.
No recopilar ni guardar datos personales de los ocupantes (ubicación individual, imágenes de rostros) más allá de lo necesario para la emergencia.

Parte 6 — Preguntas finales

1. **Comparación de mis respuestas 1 y 2**

La respuesta 2 sería más peligrosa si alguien la creyera sin revisar. Da identificadores CVE y versiones de Chrome (155 y 156) que parecen confiables, pero uno de los CVE se describe como corregido antes de la versión 154, lo que no encaja con “los últimos siete días”. Alguien podría parchar o reportar con datos equivocados. La respuesta 1 reconoce que no pudo confirmar los CVE y me manda al blog oficial de Google, así que es menos útil pero más segura. Para saber cuál sí buscó me fijé en el contenido: la 2 trae versiones e identificadores concretos que el modelo no tendría sin resultados de búsqueda, mientras que la 1 solo recibió información general. Las dos dicen “Herramienta usada: ddgo_search”, pero esa línea la escribe el propio modelo, así que la prueba real está en el registro del nodo.

2. **Acción que nunca dejaría que el agente decidiera solo**

Nunca dejaría que el agente ordenara una evacuación o activara y desactivara sistemas del edificio (rociadores, corte de energía, puertas), ni que descartara una lectura como falsa alarma. Si se equivoca, puede poner en riesgo a personas. El control sería que el agente solo recomiende y una persona del equipo de seguridad confirme antes de ejecutar. Si nadie confirma en un tiempo definido, el agente no actúa solo, sino que escala el aviso a otra persona. Además, cada decisión quedaría registrada en la bitácora.

3. **Dependencias y qué pasa si fallan**

Si falla Dify, el agente deja de vigilar y de responder, pero la alarma certificada del edificio sigue funcionando porque no depende de él. Si se acaban los créditos del modelo, el agente deja de razonar justo cuando hay más actividad. Es la que más me preocupa, porque puede pasar sin aviso en un momento crítico. Si falla el buscador externo, solo se afectan las consultas que necesitan información fuera de los documentos del edificio, por lo que es la de menor riesgo. Para reducir el problema pondría un aviso cuando queden pocos créditos y un mensaje claro de “agente sin servicio” para el personal.